Métodos Quantitativos

Prof. Dr. A. L. Korzenowski

Aula 01: Apresentação da Disciplina, Introdução ao R

Sobre o que trata-se esta disciplina

De acordo com a Ementa, a disciplina versa sobre estatística não paramétrica; estatística bayesiana; técnicas avançadas de análise multivariada; sistemas de equações estruturais e mineração de dados.

Nesta disciplina trabalharemos com certa flexibilidade em apenas alguns tópicos considerados relevantes. Nesta lógica, revisaresmo os conceitos de testes de hipóteses, teremos uma breve introdução ao software estatístico R e avançaremos por técnicas de analise de dados que vêm recebendo destaque nas aplicações dentro das organizações.

Conteúdos

Aula	Data	Conteúdo
		Análise de dados - Técnicas Tradicionais
1	06/03	Apresentação da disciplina, R-Package com RStudio
2	13/03	Conceitos de Testes de hipóteses e aplicações
3	20/03	Modelos Lineares de Regressão e Generalizados
4	27/03	Análise de Cluster - K-means
5	03/04	Análise Fatorial Exploratória - Testes diagnósticos e interpretações
		Big Data & Analytics
6	17/04	Introdução à Data Mining - Association Rules
7	24/04	Modelo de aprendizagem supervisionada: Artificial Neural Networks
8	08/05	Modelo de Classificação: Linear Support Vector Machine
9	15/05	Otimização Combinatória: Simulated Anealing
10	22/05	Otimização Combinatória: Genetic Algorithm
		Projeto Aplicado
11	29/05	Definição do problema - Planejamento da solução
12	05/06	Implementação da Solução
13	19/06	Implementação da Solução
14	26/06	Validação dos Resultados
15	03/07	Apresentação dos resultados - Entrega do relatório

Ferramentas

O que é o R?

Um ambiente que integra diversos programas para computação estatística e composição de gráficos.

- Permite manipulação e armazenamento de dados.
- Oferece um conjunto de operadores para cálculos sobre vetores e matrizes.
- Coloca à disposição do usuário uma grande coleção de ferramentas para análise de dados.
- Comunicação por meio de uma linguagem simples e eficaz, similar à linguagem S.

O R pode ser obtido a partir de algum *mirror* no seu site oficial *The R Project for Statistical Computing*

Se foi feita a instalação completa do R, é muito provável que esteja disponível uma vasta documentação própria do R.

- Perguntas freqüentes do R
- Perguntas freqüentes do R para ambiente Windows
- Manuais em Portable Document Format (PDF)
- Ajuda online via comando help( ).
- Ajuda em HTML (com Introdução, Busca, Pacotes, Linguagem R, Instalação e Administração, etc.)

Um comando importante – fundamental – é o help( ):

- help(FUNCAO)
- help("ASSUNTO")

Recentemente, a comunidade desenvolveu o programa RStudio, que adiciona uma série de funcionalidades visuais ao ambiente de programação, na busca de torná-lo mais amigável. O RStudio é um ambiente de desenvolvimento integrado (IDE) para R. Ele inclui um console, editor de realce de sintaxe que suporta execução direta de código, além de ferramentas para plotagem, histórico, depuração e gerenciamento de espaço de trabalho.

Utilizaremos a opção RStudio Cloud, uma plataforma on-line onde é necessário apenas um navegador e acesso a internet. O RStudio, seja na versão local ou na Cloud, tem a seguinte aparência:

Tarefa

1. Acessar o RStudio Cloud no link http://rstudio.cloud.
2. Fazer o cadastro.
3. Criar um projeto para a disciplina no ambiente.
4. Explorar os espaços e utilizar os primeiros comandos.

Introdução ao *software* e linguagem R

O ideal para aprender a usar o R é "usá-lo!". Então, a melhor forma de se familiarizar com os comandos do R é ler um texto introdutório e ao mesmo tempo ir digitando os comandos no R e observando os resultados, gráficos, etc. Aprender a usar o R pode ser difícil e trabalhoso, mas lembre-se, o investimento será para você!

Para usar o R é necessário conhecer e digitar comandos. Alguns usuários acostumados com outros programas notarão de início a falta de "menus" (opções para clicar). Na medida em que utilizam o programa, os usuários (ou boa parte deles) tendem a preferir o mecanismo de comandos, pois é mais flexível e com mais recursos. Algumas pessoas desenvolveram módulos de "clique-clique" para o R, como o R-commander. Porem, eu acredito que ao usar um módulo de "clique-clique" perdemos a chance de aprender uma das maiores potencialidades e virtudes do R, que é a programação.

O R é case-sensitive, isto é, ele diferencia letras maiúsculas de minúsculas, portanto A é diferente de a. O separador de casas decimais é ponto ".". A vírgula é usada para separar argumentos (informações). Não é recomendado o uso de acentos em palavras (qualquer nome que for salvar em um computador, não só no R, evite usar acentos. Acentos são comandos usados em programação e podem causar erros, por exemplo, em documentos do word e excel).

O R é um programa leve (ocupa pouco espaço e memória) e geralmente roda rápido, até em computadores não muito bons. Isso porque ao instalarmos o R apenas as configurações mínimas para seu funcionamento básico são instaladas (pacotes que vem na instalação "base"). Para realizar tarefas mais complicadas pode

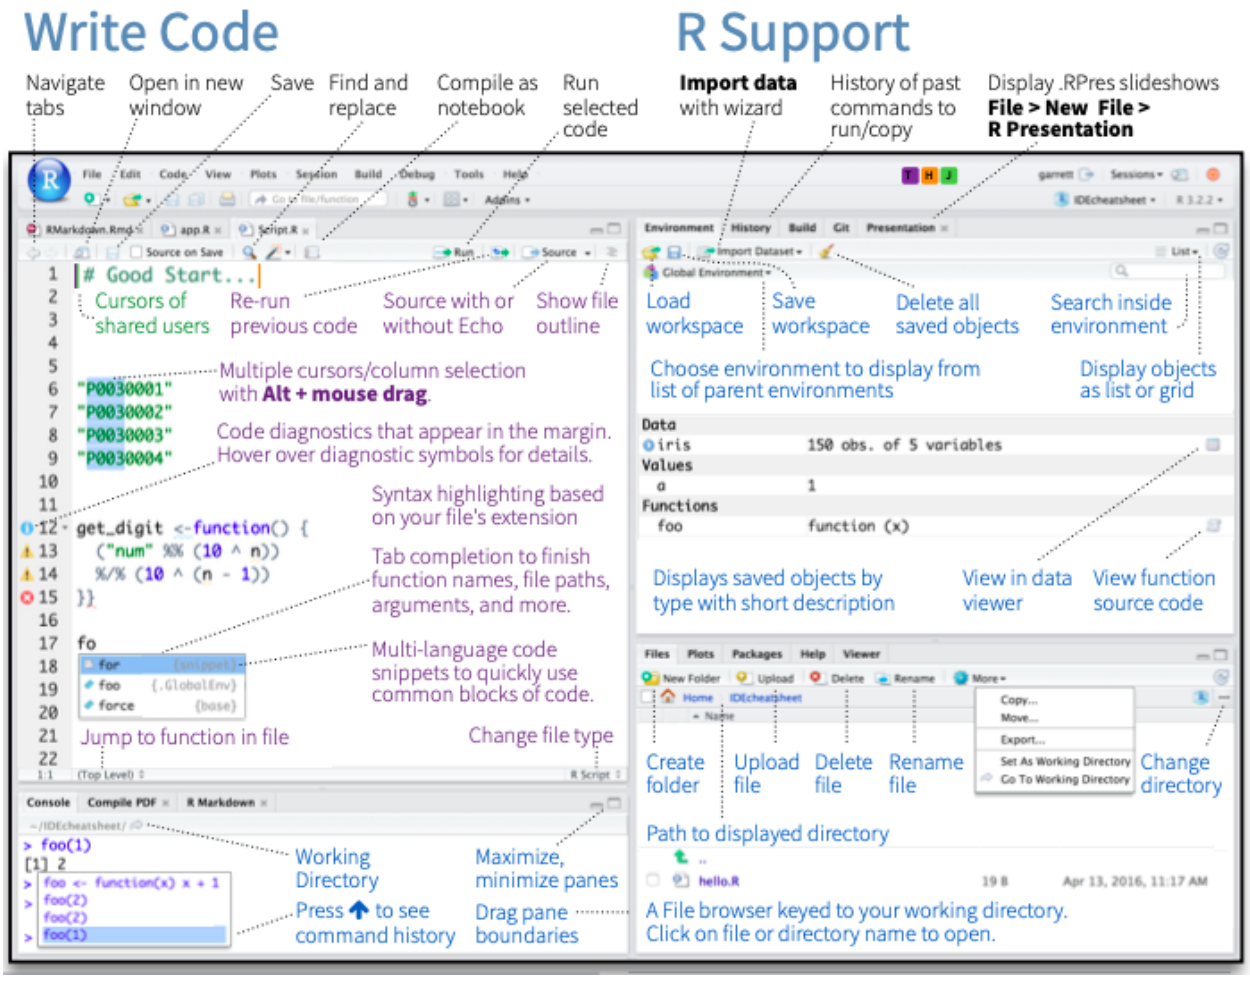

Figure 1: RStudio

ser necessário instalar pacotes adicionais (packages). Não basta apenas instalar um pacote. Para usá-lo é necessário "carregar" o pacote sempre que você abrir o R e for usá-lo. Use a função library para rodar um pacote.

No R existe um comando que mostra como citar o R ou um de seus pacotes. Veja como fazer:

```
citation()
```

```
##
## To cite R in publications use:
##
##   R Core Team (2019). R: A language and environment for
##   statistical computing. R Foundation for Statistical Computing,
##   Vienna, Austria. URL https://www.R-project.org/.
##
## A BibTeX entry for LaTeX users is
##
##   @Manual{,
##     title = {R: A Language and Environment for Statistical Computing},
##     author = {{R Core Team}},
##     organization = {R Foundation for Statistical Computing},
##     address = {Vienna, Austria},
##     year = {2019},
##     url = {https://www.R-project.org/},
##   }
##
## We have invested a lot of time and effort in creating R, please
## cite it when using it for data analysis. See also
## 'citation("pkgname")' for citing R packages.
```

Para citar um pacote, por exemplo psych, basta colocar o nome do pacote entre aspas:

```
citation("psych")
```

```
##
## To cite the psych package in publications use:
##
##   Revelle, W. (2018) psych: Procedures for Personality and
##   Psychological Research, Northwestern University, Evanston,
##   Illinois, USA, https://CRAN.R-project.org/package=psych Version
##   = 1.8.12.
##
## A BibTeX entry for LaTeX users is
##
##   @Manual{,
##     title = {psych: Procedures for Psychological, Psychometric, and Personality Research},
##     author = {William Revelle},
##     organization = { Northwestern University},
##     address = { Evanston, Illinois},
##     year = {2018},
##     note = {R package version 1.8.12},
##     url = {https://CRAN.R-project.org/package=psych},
##   }
```

R como calculadora

O forma de uso mais básica do R é usá-lo como calculadora. Os operadores matemáticos básicos são: + para soma, - subtração, * multiplicação, / divisão e ^ exponenciação. Digite as seguintes operações na linha de comandos do R:

```
2+3
2*3
2/3
2^3
```

O R tem diversas funções que podemos usar para fazer os cálculos desejados. O uso básico de uma função é escrever o nome da função e colocar os argumentos entre parênteses, por exemplo: **função(argumentos)**. **função** especifica qual função irá usar e **argumentos** especifica os argumentos que serão avaliados pela função. Não se assuste com esses nomes, com um pouco de pratica eles se tornarão triviais. Rode as seguintes linhas de código no R para comprender melhor o uso de funções:

```
sqrt(9)       # Extrai a raiz quadrada dos argumentos entre parênteses
sqrt(2*3^2)   # Extrai a raiz quadrada de 18
sqrt((2*3)^2) #Extrai a raiz quadrada de 36
seq(from = 1, to = 5, by = 1 )  # Gera uma sequência de um até 5 em intervalo regular
prod(1,2,3,4) # Determina o produtório 1x2x3x4
```

Objetos do R (O que são?):

O que são os Objetos do R? Existem muitos tipos de objetos no R que só passamos a conhecê-los bem com o passar do tempo. Por enquanto vamos aprender os tipos básicos de objetos.

1. vetores: uma seqüência de valores numéricos ou de caracteres (letras, palavras).
2. matrizes: coleção de vetores em linhas e colunas, todos os vetores dever ser do mesmo tipo (numérico ou de caracteres).
3. dataframe: O mesmo que uma matriz, mas aceita vetores de tipos diferentes (numérico e caracteres). Geralmente nós guardamos nossos dados em objetos do tipo data frame, pois sempre temos variáveis numéricas e variáveis categóricas (por exemplo, largura do rio e nome do rio, respectivamente).
4. listas: conjunto de vetores, dataframes ou de matrizes. Não precisam ter o mesmo comprimento, é a forma que a maioria das funções retorna os resultados.
5. funções: as funções criadas para fazer diversos cálculos também são objetos do R. No decorrer da apostila você verá exemplos de cada um destes objetos.

Algumas funções do R possuem demonstrações de uso. Vejamos alguns exemplos:

```
demo(graphics)
demo(persp)
```

Como criar objetos?

O comando <- (sinal de menor e sinal de menos) significa assinalar (assign). Indica que tudo que vem após este comando será salvo com o nome que vem antes. Se quisermos atribuir um vetor de dados ao nome **x** para cálculos posteriores, podemos fazê-lo da seguinte forma:

```r
x <- c(2,3,4,5,6,9,12,14,16,17,21,24)
```

onde **x** é o nome atribuído ao vetor e **c** a função concatenar que agrupa os dados entre parênteses dentro do objeto que será criado. Para ver os valores (o conteúdo de um objeto), basta digitar o nome do objeto na linha de comandos.

```
##  [1]  2  3  4  5  6  9 12 14 16 17 21 24
```

Para fazer operações com objetos vetorias, existem funções úteis, como por exemplo algumas funções estatísticas.

```r
length(x) # Tamanho do vetor
```

```
## [1] 12
```

```r
min(x)    # Mínimo valor de x
```

```
## [1] 2
```

```r
max(x)    # Máximo valor de x
```

```
## [1] 24
```

```r
mean(x)   # Média aritmética de x
```

```
## [1] 11.08333
```

```r
sd(x)     # Desvio-padrão de x
```

```
## [1] 7.378819
```

Se quiser usar estas informações posteriormente, basta salvá-las em um objeto no ambiente que ele poderá ser chamado a qualquer tempo.

```r
sum(x)
```

```
## [1] 133
```

```r
media <- mean(x)
n <- length(x)
media
```

```
## [1] 11.08333
```

```r
n
```

```
## [1] 12
```

```
media * n
```

```
## [1] 133
```

Acessar valores dentro de um objeto [colchetes]

Caso queira acessar apenas um valor do conjunto de dados use colchetes [ ]. Isto é possível porque o R salva os objetos como vetores, ou seja, a sequencia na qual você incluiu os dados é preservada. Por exemplo, vamos acessar o quinto valor do objeto **x**.

```
x[5]
```

```
## [1] 6
```

ou os valores de ordem 3, 5 e 7...

```
x[c(3,5,7)]
```

```
## [1]  4  6 12
```

Se deseja substituir ou excluir um valor, proceda da seguinta forma:

```
x
```

```
##  [1]  2  3  4  5  6  9 12 14 16 17 21 24
```

```
x[10] <- 99   # Altera o décimo valor para 99
x
```

```
##  [1]  2  3  4  5  6  9 12 14 16 99 21 24
```

```
x[-10]        # Note que o décimo valor (99) não aparece
```

```
##  [1]  2  3  4  5  6  9 12 14 16 21 24
```

Transformar dados

Em alguns casos é necessário, ou recomendado, que você transforme seus dados antes de fazer suas análises. Transformações comumente utilizadas são log e raiz quadrada.

```
sqrt(x)   # Raiz quadrada dos valores de x
```

```
##  [1] 1.414214 1.732051 2.000000 2.236068 2.449490 3.000000 3.464102
##  [8] 3.741657 4.000000 9.949874 4.582576 4.898979
```

```r
log10(x)  # log(x) na base 10, apenas
```

```
##  [1] 0.3010300 0.4771213 0.6020600 0.6989700 0.7781513 0.9542425 1.0791812
##  [8] 1.1461280 1.2041200 1.9956352 1.3222193 1.3802112
```

```r
log(x)    # logaritmo natural de x
```

```
##  [1] 0.6931472 1.0986123 1.3862944 1.6094379 1.7917595 2.1972246 2.4849066
##  [8] 2.6390573 2.7725887 4.5951199 3.0445224 3.1780538
```

Para salvar os dados transformados dê um nome ao resultado. Por exemplo:

```r
x.log<-log10(x) # salva um objeto com os valores de aves em log
```

Gerar dados aleatórios

1. Gerar dados aleatórios com distribuição uniforme

- runif(n, min=0, max=1) gera uma distribuição uniforme com n valores, começando em min e terminando em max.

2. Gerar dados aleatórios com distribuição normal

- rnorm(n, mean=0, sd=1) gera n valores com distribuição normal, com média 0 e desvio padrão 1.

```r
set.seed(42)      # Fixa semente aleatória para reprodutibilidade
k <- runif(n = 100, min = 2, max = 17)
l <- rnorm(n = 100, mean = 100, sd = 15)
hist(k)           # Histograma dos dados k
```

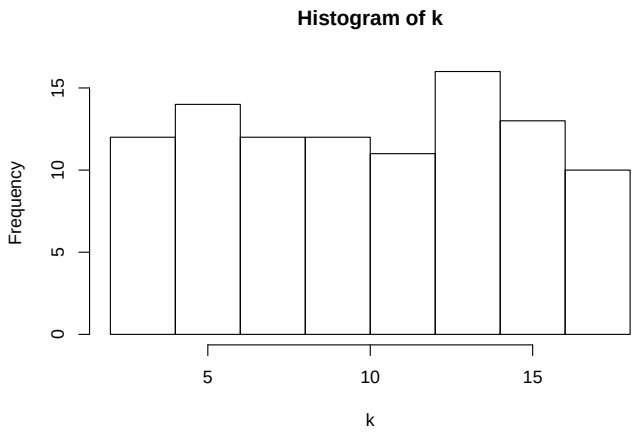


```r
hist(l)           # Histograma dos dados l
```

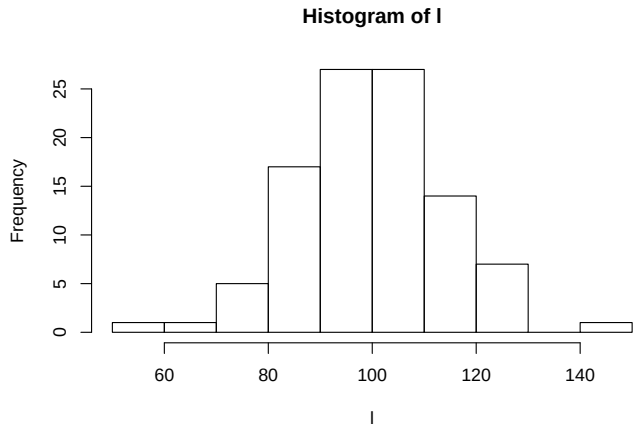

Veja o help da função **?Distributions** para conhecer outras formar de gerar dados aleatórios com diferentes distribuições.

Selecionar amostras aleatórias, ordenar e atribuir postos (ranks) aos dados

A função sample é utilizada para realizar amostras aleatórias:

sample(x, size=1, replace = FALSE) onde x é o conjunto de dados do qual as amostras serão retiradas, size é o número de amostras e replace é onde você indica se a amostra deve ser feita com reposição (TRUE) ou sem reposição (FALSE). Assim, **sample(1:10,5)** seleciona 5 dados com valores entre 1 e 10. Como não especificamos o argumento replace o padrão é considerar que a amostra é sem reposição (= FALSE). Com a função sample nós podemos criar varios processos de amostragem aleatória. Por exemplo, vamos criar uma moeda e "jogá-la" para ver quantas caras e quantas coroas saem em 10 jogadas.

```
moeda<-c("CARA","COROA") # primeiro criamos a moeda
sample(moeda,10,replace=TRUE)
```

```
##  [1] "CARA"  "COROA" "COROA" "COROA" "CARA"  "CARA"  "COROA" "CARA"
##  [9] "CARA"  "COROA"
```

A função sort coloca os valores de um objeto em ordem crescente ou em ordem decrescente.

```
exemplo<-sample(1:100,10)
sort(exemplo) # para colocar em ordem crescente
```

```
##  [1] 26 37 43 45 54 55 58 84 98 99
```

```
sort(exemplo, decreasing=TRUE) # para colocar em ordem decrescente
```

```
##  [1] 99 98 84 58 55 54 45 43 37 26
```

A função order retorna a posição original de cada valor do objeto **exemplo** caso os valores do objeto **exemplo** sejam colocados em ordem.

```
order(exemplo)
```

```
##  [1]  1  9 10  8  2  5  7  4  6  3
```

Note que o primeiro valor acima é 7, isso indica que se quisermos colocar o objeto **exemplo** em ordem crescente o primeiro valor deverá ser o sétimo valor do **exemplo**, que é o valor 2 (o menor deles). Na sequência devemos colocar o quinto valor do objeto **exemplo**, que é 24, depois o segundo, depois o nono... até que objeto **exemplo** fique em ordem crescente.

```
order(exemplo,decreasing=TRUE)
```

```
##  [1]  3  6  4  7  5  2  8 10  9  1
```

É importante entender o comando order, pois ele é muito usado para colocar uma planilha de dados seguindo a ordem de alguma de suas variáveis.

A função rank atribui postos aos valores de um objeto.

```
exemplo # apenas para relembrar os valores do exemplo
```

```
##  [1] 26 54 99 84 55 98 58 45 37 43
```

```
rank(exemplo) # Para atribuir postos (ranks) aos valores do exemplo
```

```
##  [1]  1  5 10  8  6  9  7  4  2  3
```

Veja que 94 é o maior valor do exemplo, portanto recebe o maior rank, no caso 10.

Importar conjunto de dados para o R

A tarefa de importar conjuntos de dados na versão nativa do R sempre foi um tanto desafiadora. Funções e argumentos além da necessidade de instalar e carregar pacotes especificos se os dados não estavam no formato adequado. Com o RStudio, a tarefa ficou muito simplificada pela facilidade de utilizar os menus - algo tipo *Click-and-Play*!

Crie um arquivo em Excel e explore o ambiente do RStudio. Na aba Environment, utilize a opção Import Dataset. Os pacotes necessários para carregar a sua planilha serão instalados e carregados pelo RStudio. LEMBRE-SE DE COMO DEVE SER CONSTRUÍDA UMA BASE DE DADOS PARA ANÁLISE!!!

Para selecionar (extrair) apenas partes do nosso conjunto de dados usando [ ] colchetes.

O uso de colchetes funciona assim: [linhas, colunas], onde está escrito linhas você especifica as linhas desejadas, na maioria dos casos cada linha indica uma unidade amostral. Onde está escrito colunas, você pode especificar as colunas (atributos) que deseja selecionar.

Se você ainda não carregou uma matriz de dados para o R, vamos criar uma **data.frame** de dados aleatórios com a função **matrix** e selecionar parte dos dados como exemplo. Na sua planilha carregada funciona da mesma forma.

```
dados <- as.data.frame(matrix(data = rnorm(n=20, mean = 20, sd = 5), ncol = 5))
dados
```

```
##         V1        V2       V3       V4       V5
## 1 18.65256 23.384038 17.61878 11.30892 15.12192
## 2 17.08292  5.884514 17.26544 18.38492 19.69539
## 3 27.57602 18.723853 13.32439 26.70559 28.29862
## 4 25.01371 19.753900 18.20484 20.96265 19.62994
```

```
dados[1,3] # dado da linha 1 e coluna 3
```

```
## [1] 17.61878
```

```
dados[2,]  # dados da linha 2
```

```
##         V1       V2       V3       V4       V5
## 2 17.08292 5.884514 17.26544 18.38492 19.69539
```

```
dados[,5]  # dados da coluna 5
```

```
## [1] 15.12192 19.69539 28.29862 19.62994
```

```
dados[2:3,2:4] # submatriz com dados das linhas 2 e 3 e colunas 2 a 4
```

```
##          V2       V3       V4
## 2  5.884514 17.26544 18.38492
## 3 18.723853 13.32439 26.70559
```

A sequência da apredizagem do R se dá com uso, leitura de manuais, ajuda e fóruns da internet... Mãos a obra

Atividades

1. Suponha que você marcou o tempo que leva para chegar a cada uma de suas parcelas no campo. Os tempos em minutos foram: 18, 14, 14, 15, 14, 34, 16, 17, 21, 26. Passe estes valores para o R, chame o objeto de tempo. Usando funções do R ache o tempo máximo, mínimo e o tempo médio que você levou gasta para chegar em suas parcelas.

- Ops, o valor 34 foi um erro, ele na verdade é 15. Sem digitar tudo novamente, e usando colchetes [ ], mude o valor e calcule novamente o tempo médio.

2. Calcule o módulo de $2^3 \times -3^2$
3. Suponha que você coletou 10 amostras em duas reservas, as 5 primeiras amostras foram na reserva A e as 5 ultimas na reserva B. Use a função **rep** para criar um objeto chamado locais que contenha 5 letras A seguidas por cinco letras B.
4. Suponha que você deseje jogar na mega-sena, mas não sabe quais números jogar, use a função **sample** do R para escolher seis números para você. Lembre que a mega-sena tem valores de 1 a 60.
5. Einstein disse que Deus não joga dados, mas o R joga! Simule o resultado de 25 jogadas de um dado.
6. Crie um objeto com estes dados: 9 0 10 13 15 17 18 17 22 11 15 e chame-o de temp. Agora faça as seguintes transformações com esses dados:

- raiz quadrada de temp,
- log natural de temp,
- log(x+1) de temp,
- eleve os valores de temp ao quadrado.

7. Crie um objeto chamado info que contem seu nome, idade, altura, peso, email e telefone.